



Projeto 1

Inteligência Artificial

Matheus Henrique de Arruda



Sumário

- 1.Contextualização/Problemática
- 2.Considerações sobre os dados
- 3.Objetivo Geral
- 4.Limpeza dos dados
- 5.Metodologia
- 6.Análises
- 7.Conclusões



1. Contextualização/Problemática

Atualmente, uma empresa do setor calçadista possui um alto índice de ruptura e excesso de estoque, ou seja, em alguns momentos há falta do produto no momento da venda e também há excesso de produção em períodos ou produtos de baixa demanda.

A empresa utiliza uma média móvel de 3 meses para a previsão. Esse método, por exemplo, não leva em conta a sazonalidade das vendas de dos tipos de calçados, tornando esse método puramente quantitativo e não qualitativo

2. Consideração Sobre os Dados


- Foi realizada uma Análise Exploratória de Dados com a finalidade de identificar possíveis erros na database e qual a melhor solução para cada caso.




Pandas




2.1 Produtos




2.2 Vendas anuais




2.3 Tendência de vendas



2.4 Sazonalidade



2.5 Anual



3. Objetivo Geral

O principal objetivo da abordagem é encontrar uma solução melhor que a média móvel implementada atualmente na empresa.

Como solução, propõe-se a implementação de Redes Neurais Recorrentes (RNN), utilizando a arquitetura LSTM




4. Limpeza dos Dados

- Dos casos identificados:
 - A seção de “Sneaker” e “Sneakers” aparentavam ser um erro de nomenclatura para a mesma classificação de produto, assim, ambas foram agrupadas em somente uma: Sneakers. Os dados de Novembro de 2021 apresentavam valores repetidos, porém com uma pequena diferença entre os valores para cada caso, foi utilizada a média entre ambos os valores;
 - A tabela foi simplificada, agrupando cada um dos modelos em sua classificação com o valor total das vendas estando dividido somente entre as categoria(Boot, Shoes, Sandals, Sneakers) e o conjunto mês e ano de cada dado(Fizemos uma análise a nível de categorias)

5. Metodologia


As redes neurais tradicionais não armazenam informações no tempo (previsões independentes), já as redes recorrentes são diferenciadas das redes feedforward pelo loop de feedback conectado às suas decisões anteriores, ingerindo suas próprias saídas momento após momento como entrada.





5. Arquitetura LSTM (Long-Short Term Memory)

A LSTM é uma arquitetura de rede neural recorrente (RNN) que “lembra” valores em intervalos arbitrários.

- A forget gate (Liberar memória): Decide quais partes do cell state continuam importantes, ou seja, descobre quais detalhes devem ser descartados do bloco; ele examina o estado anterior (h_{t-1}) e a entrada de conteúdo (x_t) e gera um número entre 0 (apague isso) e 1 (mantenha isso) para cada número no estado da célula C_{t-1} .
- A Input gate (Adicionar na memória): Decide quais informações da memória de curto prazo devem ser adicionadas ao cell state (armazenadas); e
- A output gate (Ler da memória): Decide quais partes do cell state são importantes no instante atual para gerar o output.



5. Implementação da RNN



```
#Função que aplica a rede neural
def RNN(previsores, qt_real):
    #Arquitetura da rede neural
    regressor = Sequential()
    regressor.add(LSTM(units=100, return_sequences=True, input_shape=(previsores.shape[1], 1)))
    regressor.add(Dropout(0.3)) #Ir  zerar 30% das entradas (Ajuda a prevenir overfitting)

    regressor.add(LSTM(units=40, return_sequences=True))
    regressor.add(Dropout(0.3))

    regressor.add(LSTM(units=50, return_sequences=True))
    regressor.add(Dropout(0.3))

    regressor.add(LSTM(units=60, return_sequences=False))
    regressor.add(Dropout(0.2))

    #Camada de sa da
    regressor.add(Dense(units= 1, activation='linear'))

    regressor.compile(optimizer='rmsprop', loss='mean_squared_error', metrics = ['mean_absolute_error'])

    #mc = ModelCheckpoint('Best_weights.h5', save_best_only=True, monitor='loss', verbose=1) #Salva os melhores pesos da RN

    regressor.fit(previsores, qt_real, epochs=200, batch_size=12)
    return regressor
```

5. Redes Neurais - Análises dez/2022 - mar/2023

ds_product_line	qt_sale	Previsão_M1	Previsão_M2	Previsão_M3
Boot	263267.0	248657.171875	248788.359375	249192.734375
Boot	223118.0	208973.375000	209040.140625	209413.937500
Boot	215163.0	210810.312500	210842.906250	210949.656250
Boot	184398.0	217290.125000	217290.781250	217308.687500

ds_product_line	qt_sale	Previsão_M1	Previsão_M2	Previsão_M3
Sandals	661730.0	523233.40625	525512.5625	527561.0625
Sandals	576581.0	520166.56250	522499.4375	528004.3750
Sandals	573049.0	528174.12500	528735.8750	533431.0000
Sandals	481353.0	541623.00000	541583.3125	542520.0000

5. Análises - Redes Neurais

ds_product_line	qt_sale	Previsão_M1	Previsão_M2	Previsão_M3
Shoes	1227099.0	1.117608e+06	1.117715e+06	1.118068e+06
Shoes	1052338.0	9.492761e+05	9.527423e+05	9.765859e+05
Shoes	944811.0	7.522096e+05	7.529458e+05	7.562139e+05
Shoes	812154.0	7.584313e+05	7.598244e+05	7.631146e+05

Quais os produtos com as melhores e piores previsões?

ds_product_line	qt_sale	Previsão_M1	Previsão_M2	Previsão_M3
Sneakers	564820.0	521174.87500	521799.40625	523489.40625
Sneakers	521048.0	441946.81250	441819.96875	442342.62500
Sneakers	511301.0	427787.03125	427110.71875	426933.37500
Sneakers	441090.0	426019.87500	424914.21875	423597.50000

5. Redes Neurais - Erro Percentual Absoluto Médio

	Product	Month	MAPE
0	Boot	Previsão_M1	8.494402
1	Boot	Previsão_M2	8.493809
2	Boot	Previsão_M3	8.495773
3	Sandals	Previsão_M1	13.298595
4	Sandals	Previsão_M2	13.178319
5	Sandals	Previsão_M3	12.933757
6	Shoes	Previsão_M1	5.370404
7	Shoes	Previsão_M2	5.364929
8	Shoes	Previsão_M3	5.198539
9	Sneakers	Previsão_M1	6.853611
10	Sneakers	Previsão_M2	6.893269
11	Sneakers	Previsão_M3	6.901882

A nova previsão de demanda é melhor que o modelo atual de média móvel?

Produtos	Médias móveis
Boot	17.74
Sandals	24.93
Shoes	18.10
Sneaker	24.00

5. Redes Neurais - Erro Quadrático Médio

	Product	Month	MSE
0	Boot	Previsão_M1	5.757877e+08
1	Boot	Previsão_M2	5.750483e+08
2	Boot	Previsão_M3	5.744876e+08
3	Sandals	Previsão_M1	7.339539e+09
4	Sandals	Previsão_M2	7.219079e+09
5	Sandals	Previsão_M3	6.994375e+09
6	Shoes	Previsão_M1	6.496122e+09
7	Shoes	Previsão_M2	6.486692e+09
8	Shoes	Previsão_M3	6.270475e+09
9	Sneakers	Previsão_M1	2.321209e+09
10	Sneakers	Previsão_M2	2.332473e+09
11	Sneakers	Previsão_M3	2.335223e+09

o MSE calcula a média dos quadrados das diferenças entre os valores previstos e os valores reais.

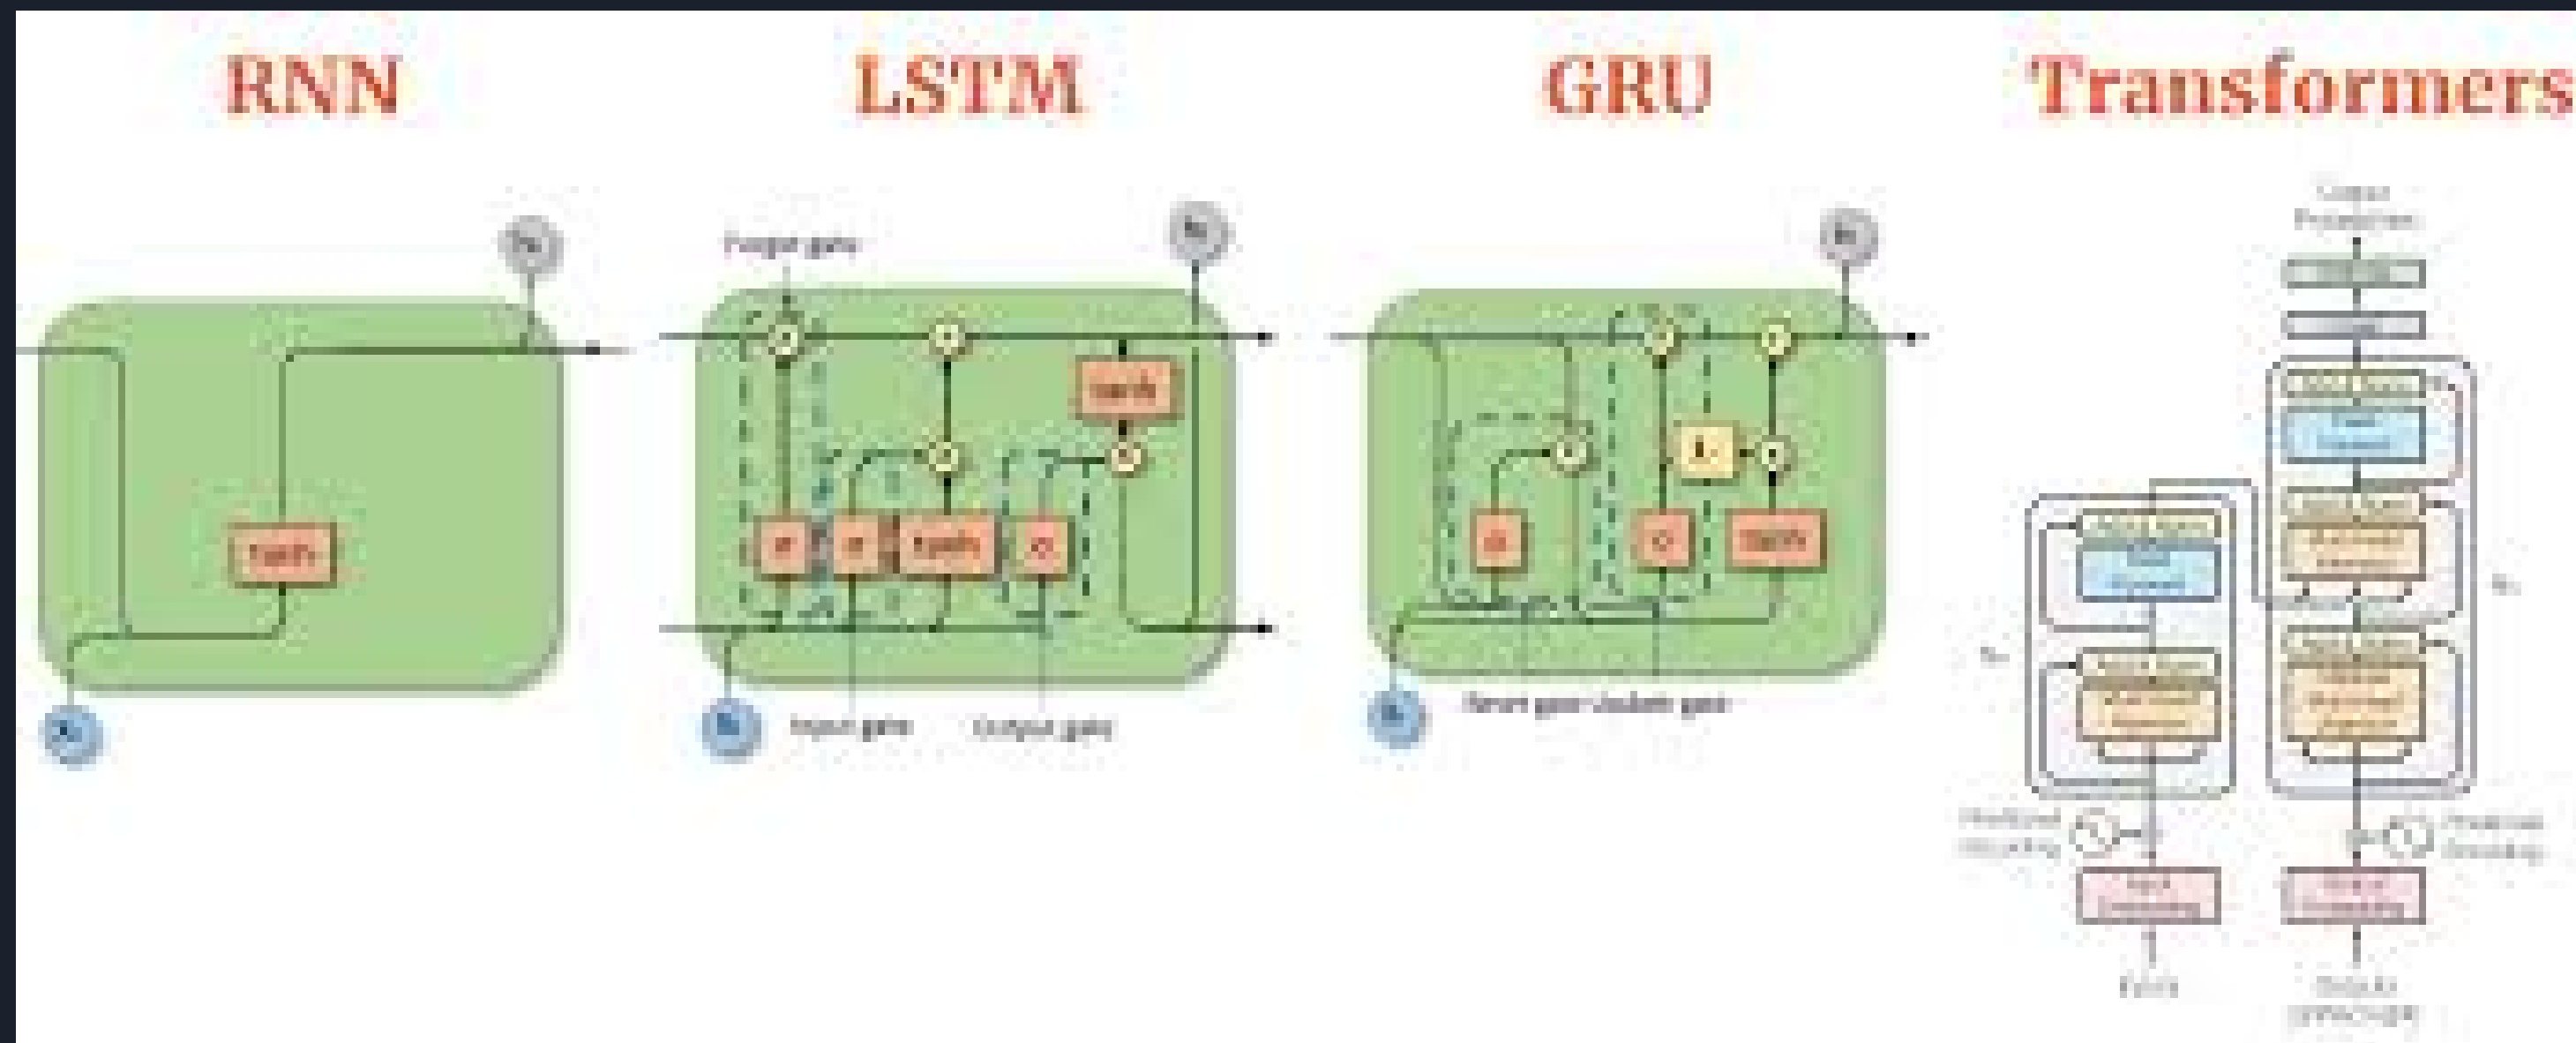
5. Redes Neurais - MAE (Mean Absolute Error)

	Product	Month	MAE
0	Boot	Previsão_M1	17040.578125
1	Boot	Previsão_M2	17044.074219
2	Boot	Previsão_M3	17042.578125
3	Sandals	Previsão_M1	78767.328125
4	Sandals	Previsão_M2	78057.492188
5	Sandals	Previsão_M3	76623.757812
6	Shoes	Previsão_M1	53559.187500
7	Shoes	Previsão_M2	53472.453125
8	Shoes	Previsão_M3	51801.000000
9	Sneakers	Previsão_M1	35416.914062
10	Sneakers	Previsão_M2	35602.210938
11	Sneakers	Previsão_M3	35640.421875

MAE a média dos valores absolutos das diferenças entre os valores previstos e os reais

5 - Comparativos e Conclusões

Em um primeiro momento, utilizar os valores obtidos com redes neurais , pois mostram um erro menor que os obtidos com a média móvel atualmente utilizada.





6. Sugestão de Ação

Para a Companhia: As análises de machine learning podem melhorar conforme mais dados são coletados e adicionados aos modelos, podendo deixá-los mais precisos.

Na análise: Ainda há análises mais elaboradas que podem ser feitas, como por exemplo, separando as análises em cada item ao invés de cada categoria, que acaba por agrupar vários itens diferentes.